【实战】免费代理！

原创： 27315

引言

作为一个个人爬虫开发，最苦恼的事之一肯定是代理ip的问题。今天我们就自己动手来做一个可用的代理IP池。

需求分析

爬取西刺代理网站中可用的高匿代理。

需要源码的同学可以关注公众号，回复“西刺代理”获取源码。

知识点

爬取数据：Requests

数据筛选：Beautifulsoup

数据库：Mongo

主要代码

网站内容很简单，这里就不做过多的解析了。直接放出部分代码

发送requests请求：

```
        def  get_response(self):
                headers  =  {
                        "User-
Agent":  "Mozilla/5.0  (Windows  NT  10.0;  Win64;  x64)  AppleWebKit/537.36  (KHTML,  like  Gecko)  Chrome/68.0.3440.106
                }
                self.response  =  requests.get(self.url,  headers=headers).text
```

提取目标内容：

```
def  get_ip_info_list(self):
        soup  =  BeautifulSoup(self.response,"lxml")
```

```
        ip_list = (soup.find(id="ip_list"))
        ip_detail = ip_list.find_all(name="tr")
        ip_detail = ip_detail[1:]
        for ip in ip_detail:
                item = {}
                item['ip'] = ip.find_all(name = "td")[1].string
                item['port'] = ip.find_all(name = 'td')[2].string
                try:
                        item['location'] = ip.find_all(name = 'td')[3].find(name = "a").string
                except:
                        item['location'] = ip.find_all(name='td')[3].string.strip()
                item['anonymous'] = ip.find_all(name = 'td')[4].string
                item['type'] = ip.find_all(name = 'td')[5].string
                item['speed'] = ip.find_all(name = 'td')[6].find(class_ = 'bar').attrs['title']
                item['connect_time'] = ip.find_all(name = 'td')[7].find(class_ = 'bar').attrs['title']
                item['alive_time'] = ip.find_all(name = 'td')[8].string
                item['verify_time'] = ip.find_all(name = 'td')[9].string
                if self.check_verify_time("20"+item['verify_time'].split(" ")[0]):
                        if not check_proxy_duplicate(item):
                                yield item
                else:
                        return
```

检查ip是否重复：

```
def check_proxy_duplicate(proxy):
        ip = proxy['ip']
        curr = pymongo.MongoClient()
        db = curr['proxy']
        collection = db['proxy']
```

```
    ip_exist = collection.find({"ip":ip})
    ip_exist_list = []
    for i in ip_exist:
        ip_exist_list.append(i)
    if ip_exist_list :
        print("%s已经存在"%ip)
        return True
    else:
        return False
```

存储至数据库：

```
def save_mongo(item):
    curr = pymongo.MongoClient()
    db = curr['proxy']
    collection = db['proxy']
    collection.insert_one(item)
    curr.close()
    print("%s 存储完成"%(item['ip']))
```

检查代理是否可用：

```
def check_proxy_enable(proxy):
    proxy_string = proxy['type'] + "://" + proxy['ip'] + ":" + proxy['port']
    if proxy['type'] == "HTTP":
        proxy_for_check = {'HTTP':proxy_string}
    elif proxy['type'] == 'HTTPS':
        proxy_for_check = {'HTTPS': proxy_string}
    try:
        requests.get("http://www.sina.com.cn",proxies=proxy_for_check)
    except:
        del_proxy_from_mongo(proxy)
```

```
        else:
            update_proxy_from_mongo(proxy)
```

爬取结果

从mongoDB中查看：

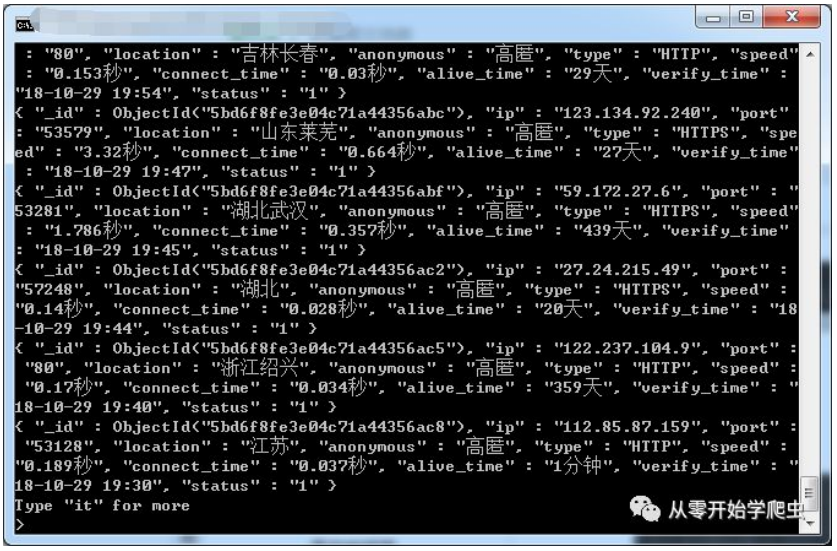

源码

需要源码的同学可以关注公众号，回复“西刺代理”获取源码。

往期内容推荐

【实战】下载歌曲只能开绿钻？NoNoNo, Python爬虫，无所不能。

【实战】爬取中国证监会指定信息披露网站——巨潮资讯网

【实战】Ajax数据爬取——头条文章图片

【实战】不知道给女朋友买什么？让爬虫告诉你！

【福利】美女照片第二弹，Scrapy框架实战应用

这一定是学爬虫的你脑中闪现过的第一道邪念！

如果你想学习Python，这些资料你一定要储备

原创不易，需要您的鼓励。如果您觉得这篇文章对您有帮助，请分享给其他需要的小伙儿伴。

长按关注公众号

个人创建了一个QQ群，面向群体为爬虫学习，群里许多志同道合的朋友，大家一起进步，可以扫描二维码申请进入，申请备注：爬虫。

最后耽误您几秒钟的时间，点下广告支持下小编。感谢！

- End -